INSTITUTO
UNIVERSITÁRIO
DE LISBOA

2025 / 2026

MODELOS DE PREVISÃO

PREVISÃO DE PREÇOS AIRBNB DE BUDAPESTE

Trabalho realizado por:
Afonso Abreu
Afonso Claudino
André Marques

1. Introdução 2
1.1 Contexto do Negócio 3
2. DATA UNDERSTANDING 3
2.1 Descrição dos Dados 3
2.2 Verificação da Qualidade dos Dados 4
2.3 Análise Exploratória de Dados (EDA) 6
2.3.1 Análise Exploratória: Distribuição do Preço 6
2.3.3 Análise Exploratória: Tipo de Alojamento (room_type) 7
2.3.4 Matriz de Correlações 8
3. DATA PREPARATION 8
3.1 Seleção de Dados (Data Selection) 8
3.2 Tratamento de Valores Omissos (NAs) 9
4. MODELING 9
4.1 Estratégia de Teste e Validação 9
4.2 Modelo 1: Regressão Linear Múltipla 9
4.3 Modelo 2: Bagging 10
4.4 Modelo 3: Random Forest 10
4.5 Modelo 4: Gradient Boosting Machines (GBM) 10
5. EVALUATION 10
5.1 Análise Comparativa de Métricas 10
5.2 Resultados dos treinos 11
6. RESULTS 12
6.1 Análise Gráfica: Previsto vs. Real 12
6.2 Análise de Resíduos e Validade Estatística 13
6.4 Interpretabilidade do Modelo / Importância das variáveis 13
6.5 Comparação 15
7. CONCLUSÃO 17

1. Introdução

No âmbito da cadeira de Modelos de Previsão, fomos encarregues com um projeto de desenvolvimento de um modelo de previsão de preços de AirBnb's em Budapeste, Hungria. Focámo-nos, como pedido, em criar modelos utilizando técnicas e algoritmos lecionados durante as aulas, ou seja, Regressão Linear Multivariada, Random Forests, Bagging e Gradient Boosting Model. Assim, evitámos algoritmos como XGBoost que são conhecidos pela sua eficácia, mas que foram apenas mencionados em aula.

1.1 Contexto do Negócio

O turismo na cidade de Budapeste (que é o ponto turístico mais atrativo da Hungria) tem visto um constante crescimento após a quebra global de turismo em 2020[1]. A moeda húngara (HUF) é significativamente menos valiosa que o Euro para além de ter desvalorizado bastante comparativamente com o Euro nas últimas duas décadas. Mesmo assim, devemos ter em consideração que à taxa atual, 1000 HUF é o equivalente a 2,60 Euros. Para facilitar a compreensão do trabalho, convertemos a essa taxa os valores para Euro.

Budapeste está naturalmente dividida ao meio pelo Rio Danúbio, o lado da margem esquerda da cidade chama-se Buda, que é a região mais antiga da cidade, e do lado direito Peste, que é a região mais moderna e com mais comércio (também onde se encontram grande parte dos pontos turísticos).

2. DATA UNDERSTANDING

A fase de Compreensão dos Dados inicia-se com a recolha inicial dos dados e prossegue com atividades que visam familiarizar-se com os mesmos, identificar problemas de qualidade, descobrir *insights* preliminares e detetar subconjuntos interessantes para a formação de hipóteses.

2.1 Descrição dos Dados

Foi efetuada uma análise preliminar à estrutura dos dados para classificar as variáveis disponíveis e o seu potencial preditivo. O conjunto de dados é composto pelas seguintes variáveis:

- **price:** Variável numérica contínua que representa o custo diário do alojamento que é a variável alvo do nosso trabalho.
- **neighbourhood:** Variável categórica que representa os distritos de Budapeste em numeração romana.
- **latitude** e **longitude:** Variáveis numéricas que representam as coordenadas espaciais exatas do alojamento.
- **room_type:** Variável categórica que representa o tipo de alojamento (Quarto privado ou partilhado, apartamento, etc…)
- **minimum_nights:** Variável numérica discreta que representa o número mínimo de noites de aluguer aceites.
- **availability_365:** Variável numérica discreta que representa o número de dias em que o alojamento estará disponível nos próximos 365 dias.

[1] *Number of tourist arrivals (nearly 1.7 million) up 11% year-on-year and tourism nights (3.8 million) up 10%* - https://www.ksh.hu/en/first-releases/tsz/etsz2510.html

- **number_of_reviews, reviews_per_month e number_of_reviews_ltm:** Variáveis numéricas que representam, respetivamente, o total de reviews do alojamento, o número médio de reviews por mês e o número de reviews nos últimos doze meses
- **last_review:** Variável numérica que indica a data da última review feita ao alojamento em questão.

Variáveis criadas:

- **days_since_last_review:** Variável numérica que representa o número de dias desde a última review com base na last_review
- **dist_centro:** Variável numérica que representa uma pseudo distância euclideana entre as coordenadas de um alojamento e o "centro" da atividade turística da cidade.

Metadados (a excluir da modelação):

- Identificadores únicos (id, host_id) e descrições textuais não estruturadas (name, host_name, license), adicionalmente uma coluna de valores em branco (neighbourhood_group).

2.2 Verificação da Qualidade dos Dados

Antes de qualquer análise exploratória profunda, avaliou-se a "saúde" dos dados para detetar anomalias que pudessem comprometer a modelação, que acabou por ser a parte mais difícil do trabalho.

Ao analisarmos de forma geral a base de dados (retirando as linhas onde price era vazio pois não têm utilidade para o nosso trabalho) com o uso da função summary ou mesmo manualmente investigando a mesma, encontrámos vários casos caricatos, alguns deles sistemáticos:

```
> summary(dados)
       id                name              host_id           host_name           neighbourhood     latitude       longitude             room_type         price
 Length:11577       Length:11577       Length:11577       Length:11577       VII. kerület :3335   Min.   :47.39   Min.   :18.94   Entire home/apt:10746   Min.   :   10.1
 Class :character   Class :character   Class :character   Class :character   VI. kerület  :2020   1st Qu.:47.49   1st Qu.:19.06   Hotel room     :    6   1st Qu.:   41.6
 Mode  :character   Mode  :character   Mode  :character   Mode  :character   VIII. kerület:1736   Median :47.50   Median :19.06   Private room   :  784   Median :   56.9
                                                                            V. kerület   :1280   Mean   :47.50   Mean   :19.06   Shared room    :   41   Mean   :  100.2
                                                                            IX. kerület  : 841   3rd Qu.:47.51   3rd Qu.:19.07                            3rd Qu.:   85.0
                                                                            XIII. kerület: 758   Max.   :47.61   Max.   :19.32                            Max.   :81837.1
                                                                            (Other)      :1607
 minimum_nights    number_of_reviews  last_review         reviews_per_month calculated_host_listings_count availability_365 number_of_reviews_ltm   license
 Min.   :  1.000   Min.   :   0.00   Min.   :2012-05-05   Min.   : 0.010    Min.   :  1.00                 Min.   :  0.0    Min.   :  0.00        Length:11577
 1st Qu.:  1.000   1st Qu.:   8.00   1st Qu.:2025-08-04   1st Qu.: 0.730    1st Qu.:  1.00                 1st Qu.: 79.0    1st Qu.:  2.00        Class :character
 Median :  2.000   Median :  39.00   Median :2025-09-04   Median : 1.920    Median :  4.00                 Median :189.0    Median : 13.00        Mode  :character
 Mean   :  3.273   Mean   :  88.51   Mean   :2025-06-07   Mean   : 2.288    Mean   : 46.93                 Mean   :189.4    Mean   : 21.03
 3rd Qu.:  2.000   3rd Qu.: 118.00   3rd Qu.:2025-09-14   3rd Qu.: 3.520    3rd Qu.: 29.00                 3rd Qu.:299.0    3rd Qu.: 35.00
 Max.   :730.000   Max.   :1180.00   Max.   :2025-09-24   Max.   :21.670    Max.   :396.00                 Max.   :365.0    Max.   :199.00
                                     NA's   :868          NA's   :868

 days_since_last_review
 Min.   :   0.0
 1st Qu.:  10.0
 Median :  20.0
 Mean   : 108.6
 3rd Qu.:  51.0
 Max.   :4890.0
 NA's   :868
```

Os dois aspetos a notar primeiro são o custo de aluguer máximo por uma noite comparativamente com o terceiro quartil. Mesmo que 81837 euros seja um custo por noite

que é facilmente verificável ser um erro (nem que seja pelas suas 0 reviews) há bastantes outros valores atrás deste que surpreendem bastante. Outro valor que parece estar errado é minimum_nights, que tem como terceiro quartil 2 noites, mas como máximo 730 noites. Para conseguir entender ainda melhor os dados, filtrámos a base de dados em outras mais pequenas através de condições específicas, como por exemplo, longas estadias (minimum_nights > 30) ou sem reviews (number_of_reviews == 0).

Os principais obstáculos à deteção de outliers é termos a noção da existência de alojamento de luxo, mas não termos forma de o reconhecer uma vez que os dados que temos sobre cada anúncio são bastante limitados. Para além disso parece que uma parte das observações com mínimo de noites maior que 30 está a utilizar a variável price para simbolizar não o preço por noite, mas o preço por mês. Um dos exemplos salientes destas incongruências é o ID = 1283159: é difícil de acreditar que uma casa que custa 1017 euros por noite e com um mínimo de estadia de 80 noites, tenha de facto 432 reviews, até porque, mesmo assumindo que 432 é a totalidade de clientes (uma família conta como um cliente na review) que estiveram aí alojados, com um mínimo de 80 noites cada, implicaria que a casa está sem lotação há, no mínimo, 94 anos! Isto, juntamente com o facto de a última review deste alojamento ter mais de três anos, parecem indícios suficientes que o minimum_nights sozinho, ou em conjunto com o preço, foram aumentados propositadamente para afastar novos clientes sem ter de apagar o anúncio enquanto o alojamento está indisponível.

Uma forma de tentar combater este tipo de anúncio "morto" seria filtrar os dados pelo tempo desde a última review, razão pela qual criámos a variável days_since_last_review mas assim resolvemos um problema com a adição de um novo, uma vez que do total de quase 12000 observações, 900 não têm reviews. Poderíamos assumir que anúncios sem reviews fossem explicados pelo facto de serem muito novos, mas achamos tanto mais plausível que sejam anúncios com valores demasiado elevados para o que prometem e assim são "rejeitados" pelo mercado.

Não conseguindo concordar numa forma de definir outliers, acabámos apenas por usar a amplitude interquartil (ou seja, 1.5 IQR acima de Q3 e abaixo de Q1) para remover valores superiores e inferiores da base de dados. Este corte radical é geralmente considerado uma má prática uma vez que assim estamos a treinar um modelo para prever apenas uma parte dos valores reais (se bem que uma grande maioria destes). Optámos pelo mesmo também por reconhecer que com os dados que tínhamos sobre cada anúncio, seria muito difícil de criar um modelo que tivesse qualquer tipo de relevância caso não o fizéssemos. Assim, livramo-nos em parte da dificuldade de perceber o que são alojamentos de luxo já que o tecto criado pelo cálculo mencionado ficou a rondar os 150 Euros.

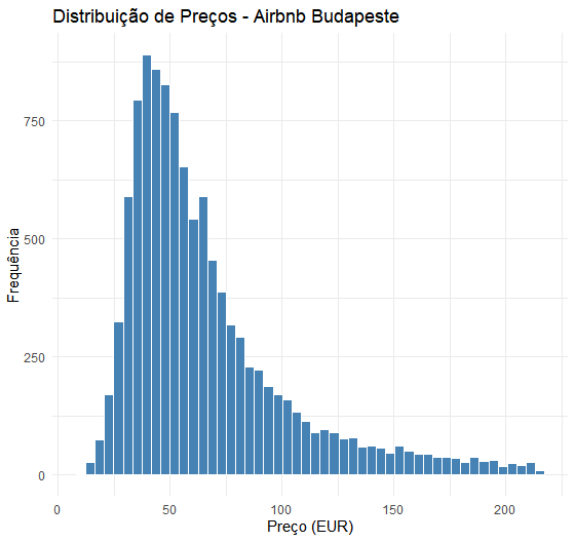
2.3 Análise Exploratória de Dados (EDA)

Já com a base de dados limpa, começámos a analisar o que nos resta.

2.3.1 Análise Exploratória: Distribuição do Preço

O histograma da variável price demonstra uma distribuição com forte assimetria positiva. A grande maioria das observações concentra-se numa gama de preços acessível, com uma cauda longa que se estende para valores elevados.

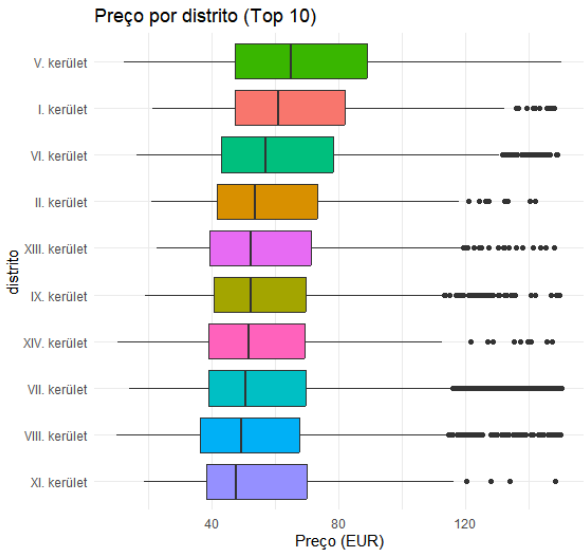
- Esta distribuição não-normal sugere que a métrica de avaliação RMSE pode ser desproporcionalmente afetada pelos valores altos mesmo após a limpeza da base de dados.
- A cauda longa para valores mais elevados é comum neste tipo de dados, assim como a *skewness* que torna muito mais frequente a observação de valores mais baixos.



A análise gráfica "Preço por Distrito (Top 10)" revela algumas disparidades regionais.

- O Distrito V destaca-se com o preço mediano mais elevado, o que é consistente com o que se esperaria (é o centro turístico, onde se situa o Parlamento e a Basílica).

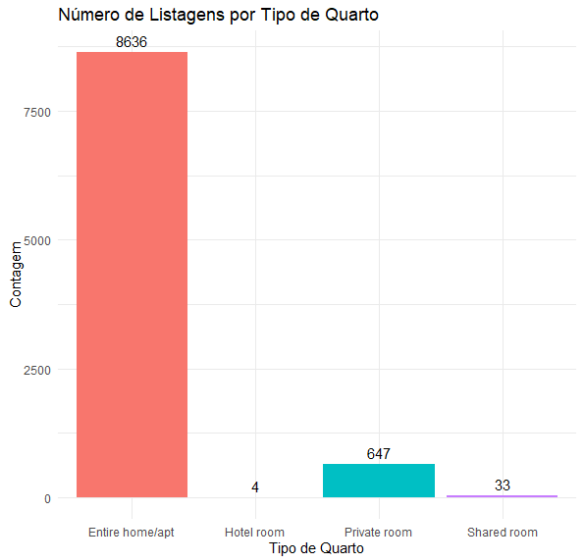
- De forma geral os valores parecem não divergir muito, isto pode ser dado ao corte demasiado radical que fizemos, mas olhando para a ordem das medianas, segue o que se esperaria olhando para o *Anexo1*.



No *Anexo2* podemos ainda ver um gráfico com a distribuição espacial dos anúncios e como a densidade de alojamentos é muito superior em Peste que em Buda.

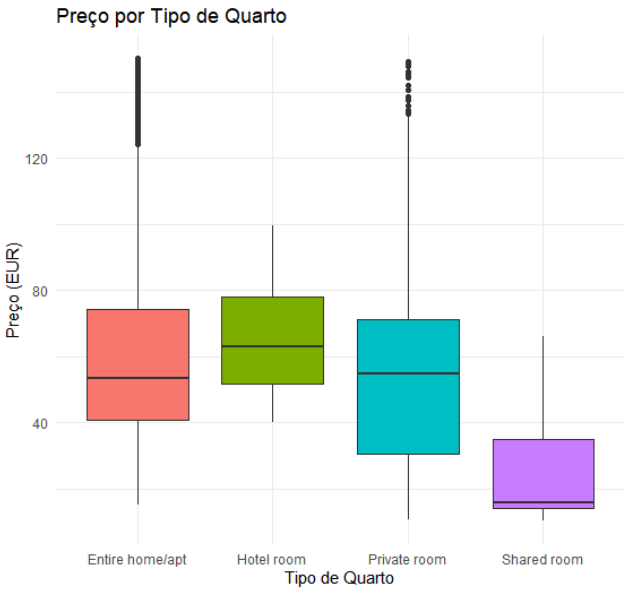
2.3.3 Análise Exploratória: Tipo de Alojamento (room_type)

1. *Entire home/apt* é claramente a maioria dentro do nosso dataset, sendo *private room* ainda significativo.



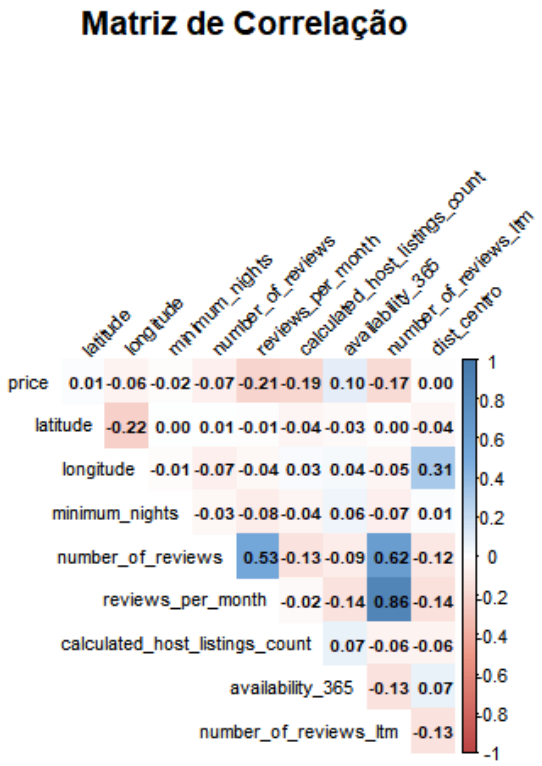
O gráfico *Boxplot* confirma aquilo que seria esperado:

1. Shared room tem os valores mais baixos
2. Private room varia bastante de preço, ainda mais que os apartamentos, mas ambos têm valores semelhantes.
3. Os quartos de hotel têm uma dispersão bastante menor do que o esperado. Isto deve-se à pouca quantidade de anúncios que têm no dataset.



2.3.4 Matriz de Correlações

A análise de correlação (Pearson) entre variáveis numéricas indicou que há alguma correlação entre as variáveis relativas ao número de reviews, mas, especialmente, uma forte correlação positiva entre reviews_per_month e number_of_review_ltm. Um valor acima de 0.80 é em geral sinal de que uma das variáveis deve ser retirada do modelo, mas neste caso, sentimos que as reviews_per_month carregam informação importante diferente do total de reviews nos últimos 12 meses. O valor em si é uma surpresa pois



esperaríamos que fosse a number_of_reviews a ter uma correlação mais alta com a reviews_per_month.

3. DATA PREPARATION

3.1 Seleção de Dados (Data Selection)

A primeira tarefa consistiu em filtrar o *dataset* original para manter apenas as colunas relevantes para o problema de regressão, excluindo ruído e redundância.

- **Atributos Excluídos:**
    - **Identificadores (id, host_id):** Variáveis de cardinalidade única ou muito elevada que não possuem padrão generalizável.

- **Texto Livre (name, host_name, license):** Embora contenham informação potencial, a sua inclusão exigiria técnicas de *Text Mining* que achámos não ser o objetivo do trabalho.
- **Variável criada:** days_since_last_review, uma vez que não encontrámos forma de confrontar os anúncios sem quaisquer reviews (supomos que se lhes atribuíssemos um número qualquer muito elevado, estaríamos a enviesar os modelos com informação que não é real)

- **Atributos Selecionados:**
  - Mantiveram-se as variáveis identificadas na Análise Exploratória como tendo potencial preditivo: neighbourhood, latitude, longitude, room_type, minimum_nights, number_of_reviews, reviews_per_month, number_of_reviews_ltm, availability_365, dist_centro e a variável alvo price.

3.2 Tratamento de Valores Omissos (NAs)

Os NAs da variáveis number_of_reviews foram substituídos por 0 nas fases iniciais de exploração da base de dados. O mesmo para as poucas observações com NA para a variável price.

4. MODELING

Utilizámos o package *caret* para treinar os modelos e uma divisão Treino 80% Teste 20% para os conjuntos.

4.1 Estratégia de Teste e Validação

Antes da execução dos algoritmos, definimos a estratégia de validação para garantir que os resultados não sofrem *overfitting*. Assim, decidimos usar validação cruzada, assegurando que o modelo é exposto a diferentes variações dos dados de treino antes da avaliação final. Considerámos *10-fold* suficiente para este objetivo.

4.2 Modelo 1: Regressão Linear Múltipla

O primeiro modelo treinado foi a Regressão Linear Múltipla.

Dado o trabalho realizado até este momento, esperava-se que fosse o modelo que mais sofresse com a falta de variáveis explicativas e a esperada não linearidade das relações entre o preço e as restantes variáveis. A sua capacidade de explicar o impacto de cada variável foi também afetada pela utilização de variáveis com correlações altas.

4.3 Modelo 2: Bagging

Uma vez que era suposto treinar modelos com base em árvores de decisão, mas com algoritmo que lhe oferecem melhorias, não treinámos nenhuma árvore de decisão individual. O primeiro modelo deste tipo a ser treinado foi o Bagging.

O algoritmo gera conjuntos de dados de treino diferentes através de amostragem com reposição. Para cada amostra, treina uma árvore de decisão completa (sem poda). A previsão final é a média das previsões de todas as árvores. Escolhemos utilizar 100 árvores (nbagg = 100).

4.4 Modelo 3: Random Forest

Enquanto o Bagging considera todas as variáveis para encontrar o melhor "corte" em cada nó da árvore, o Random Forest considera apenas um subconjunto aleatório de variáveis (mtry) em cada divisão.

A principal vantagem do modelo é que, ao forçar as árvores a usarem variáveis diferentes, impede-se que uma variável muito forte domine todas as árvores, permitindo que variáveis mais subtis contribuam para o modelo.

O modelo foi treinado com 100 árvores (ntree = 100) e em vez de forçarmos um mtry específico, utilizámos antes uma mtry_grid, com os valores de mtry a testar sendo (1, 2, 3, 4, 6, 8, 10).

4.5 Modelo 4: Gradient Boosting Machines (GBM)

Finalmente, aplicou-se o Gradient Boosting, uma técnica de *Boosting* em vez de *Bagging*.

Ao contrário do Random Forest, que constrói árvores independentes em paralelo, o GBM constrói árvores sequencialmente. Cada nova árvore é treinada para prever os resíduos da árvore anterior, corrigindo progressivamente o modelo.

Utilizámos tunelength=3 neste modelo.

5. EVALUATION

Após os modelos terem sido treinados, criámos uma tabela para comparar os seus resultados de treino através de três métricas: RMSE, MAE e R^2

5.1 Análise Comparativa de Métricas

- **MAE (*Mean Absolute Error*):** Mede o erro médio absoluto, sendo mais fácil de interpretar financeiramente.

- **RMSE (*Root Mean Squared Error*):** Penaliza erros grandes. Uma vez que fizemos um grande corte superior nos valores de alojamento, esta métrica será mais importante que o MAE.
- **R^2 (*Coefficient of Determination*):** Indica a percentagem da variância do preço que é explicada pelo modelo. Geralmente considerada a métrica principal em modelação.

5.2 Resultados dos treinos

Regressão Linear

```
> print(modelo_lm)
Linear Regression

8365 samples
  11 predictor

No pre-processing
Resampling: Cross-Validated (10 fold)
Summary of sample sizes: 7529, 7528, 7529, 7527, 7529, 7529, ...
Resampling results:

  RMSE      Rsquared   MAE
  25.21739  0.1338433  19.50919
```

Bagging

```
Bagged CART

8365 samples
  11 predictor

No pre-processing
Resampling: Cross-Validated (10 fold)
Summary of sample sizes: 7528, 7528, 7528, 7529, 7529, 7528, ...
Resampling results:

  RMSE      Rsquared   MAE
  25.15685  0.1413824  19.29525
```

Random Forest

```
  mtry  RMSE      Rsquared   MAE
   1    26.10377  0.1551180  20.37658
   2    25.04711  0.1929570  19.35890
   3    24.31331  0.2244769  18.63422
   4    23.82785  0.2442981  18.11275
   6    23.29770  0.2678338  17.54812
   8    23.12792  0.2744768  17.31838
  10    23.07563  0.2767526  17.23100

RMSE was used to select the optimal model using the smallest value.
The final value used for the model was mtry = 10.
```

GBM

```
  interaction.depth  n.trees  RMSE      Rsquared   MAE
  1                   50      25.27539  0.1407902  19.49381
  1                  100      24.89858  0.1610780  19.14401
  1                  150      24.71968  0.1697996  18.94390
  2                   50      24.73428  0.1765598  18.97468
  2                  100      24.35770  0.1946155  18.58835
  2                  150      24.19370  0.2036207  18.40916
  3                   50      24.42054  0.1953399  18.68506
  3                  100      24.09317  0.2111996  18.31412
  3                  150      23.94797  0.2193473  18.16555

Tuning parameter 'shrinkage' was held constant at a value of 0.1
Tuning parameter 'n.minobsinnode' was held constant at a value of 10
RMSE was used to select the optimal model using the smallest value.
The final values used for the model were n.trees = 150, interaction.depth = 3, shrinkage = 0.1 and n.minobsinnode = 10.
>
```

Análise dos resultados:

1. **Regressão Linear e Bagging:** Apresentaram os piores desempenhos (maior RMSE e menor R^2). Ambos surpreendentemente próximos.
2. **Gradient Boosting:** Demonstrou uma melhoria substancial face à regressão linear e ao bagging, especialmente face ao R^2.
3. **Random Forest:** Melhor em todas as métricas, excedeu o Gradient Boosting principalmente no R^2.

Assim coroámos o modelo de Random Forest com mtry=10 como o modelo para fazer as previsões do conjunto de Teste:

6. RESULTS

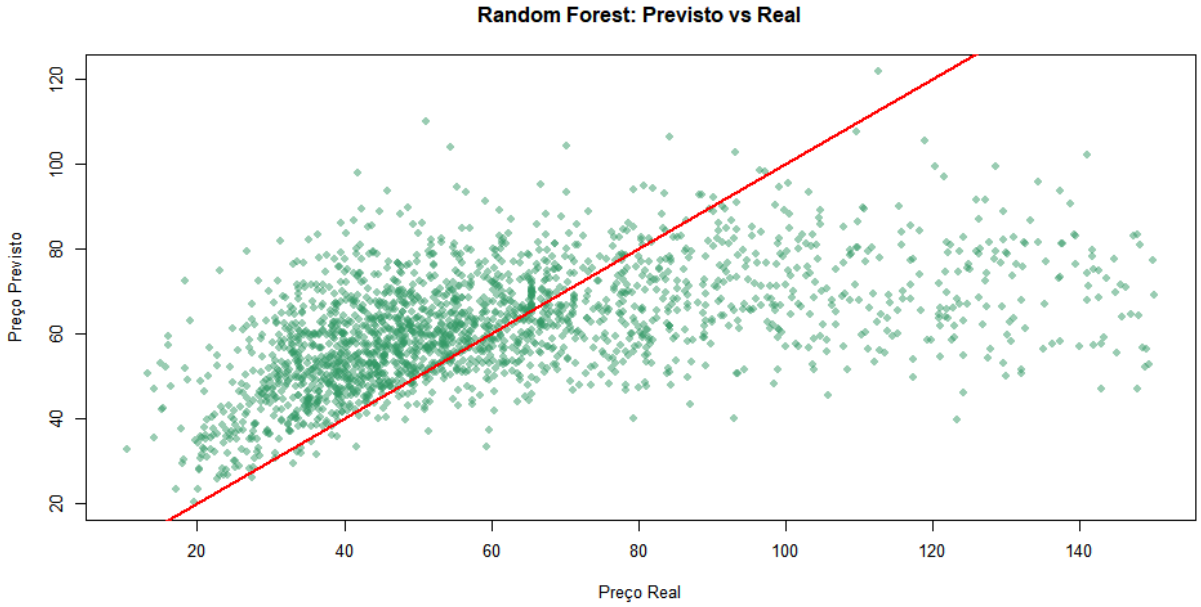
Após o teste, recebemos os seguintes resultados:

Modelo	RMSE	MAE	R2
Random Forest	24.17	17.79	0.2627

Podemos ver que os valores estão bastante próximos dos resultados do treino e que a validação cruzada teve sucesso em evitar *overfitting*.

6.1 Análise Gráfica: Previsto vs. Real

A análise visual do gráfico de dispersão:

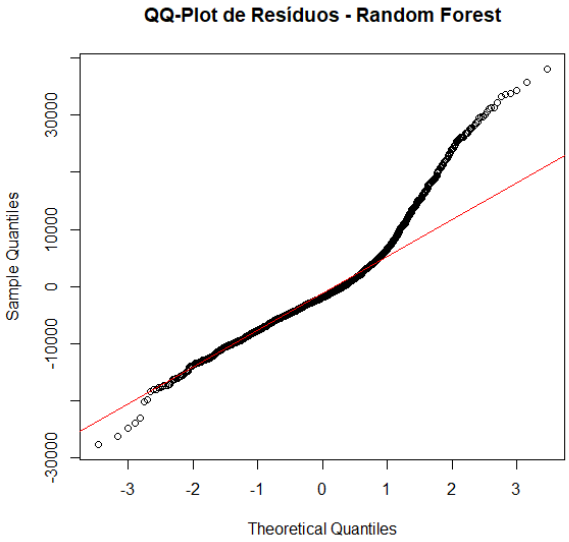


O gráfico de dispersão comprova bastante bem a nossa ideia de que o modelo (qualquer que fosse o melhor) teria muitas dificuldades em prever valor grandes pois a base de dados não continha as variáveis que melhor explicam as variações de preço, por exemplo, a diferença de um quarto privado de 50 euros por noite ou 150 pode ser a instalação de ar condicionado ou o número de camas. A partir dos 70 euros reais para cima, o nosso modelo parece recusar-se a prever algo acima dos 80 euros por noite. Mesmo assim, consegue acompanhar de alguma forma o crescimento do valor até esse ponto. Entre os 20 e os 60 aparenta preferir sobrevalorizar o alojamento, mas a "mancha" de sobrevalorização parece seguir, mesmo que não muito fidedignamente, a linha de previsão perfeita.

6.2 Análise de Resíduos e Validade Estatística

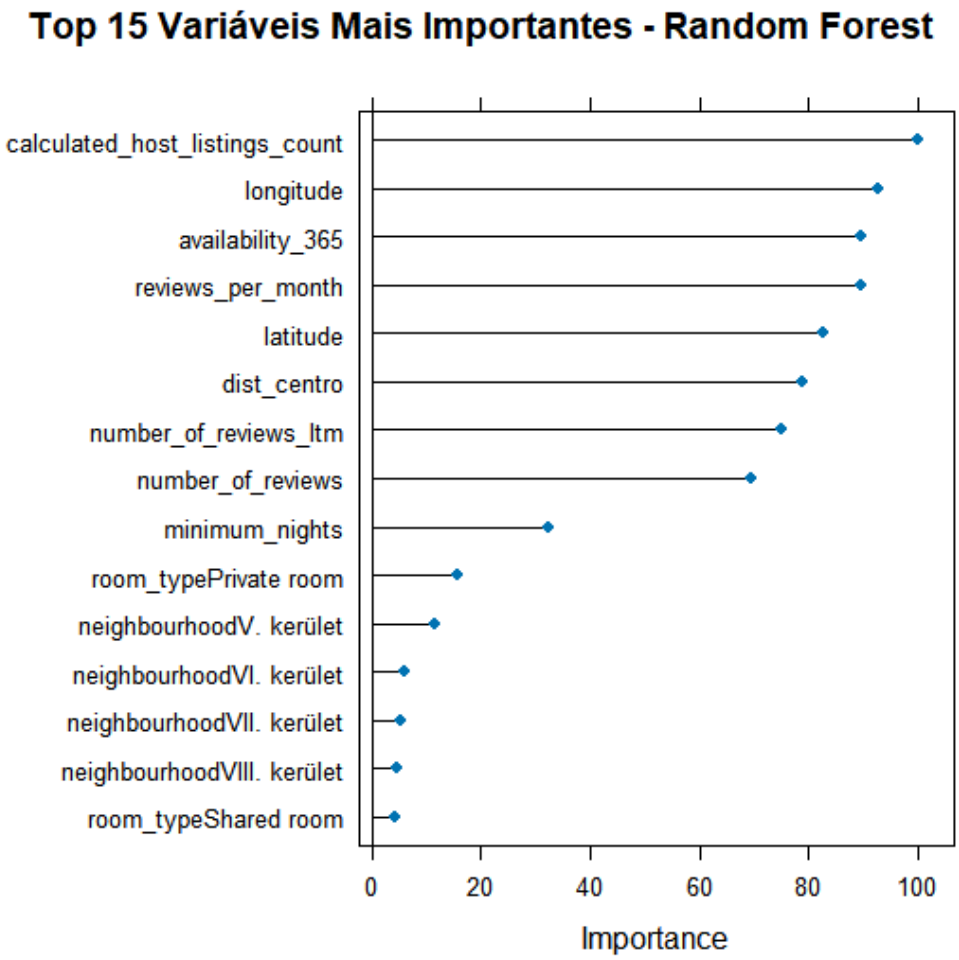
Para validar a robustez do modelo, analisou-se a distribuição dos erros (resíduos).

A análise de resíduos via QQ-Plot demonstra que o modelo Random Forest apresenta um comportamento robusto e estatisticamente válido para o segmento standard (que representa a maioria das listagens), evidenciado pela distribuição normal dos resíduos na gama central. Contudo, observam-se desvios significativos nas caudas da distribuição, indicando erros sistemáticos na previsão de valores extremos. Esta limitação deve-se, provavelmente, à escassez de variáveis que expliquem o aumento do preço e, no extremo contrário, o que faz um alojamento tão barato.



6.4 Interpretabilidade do Modelo / Importância das variáveis

A análise da importância das variáveis é essencial para converter a natureza de "caixa-negra" da Random Forest em algo interpretável, permitindo identificar quais os preditores que mais contribuem para a variação do preço e validar a coerência teórica dos dados analisados:



A hierarquia de importância das variáveis foi uma surpresa. O distrito da cidade ou mesmo o tipo de quarto, que seria de esperar serem das variáveis mais importantes, não entram sequer nas primeiras 10. Mas há forma de interpretar vários destes valores:

Possivelmente, a "irrelevância" dos distritos surge apenas pela introdução da variável dist_centro, que tem as coordenadas algures perto do centro da zona movimentada de Peste, a área conhecida pelo comércio. É criada uma redundância uma vez que a distância do alojamento ao centro está diretamente relacionada com o Distrito onde se encontra. O mesmo se pode dizer com as duas variáveis ainda mais obvias "latitude" e "longitude". As três juntas fazem com que os distritos por si não sejam importantes na decisão das árvores.

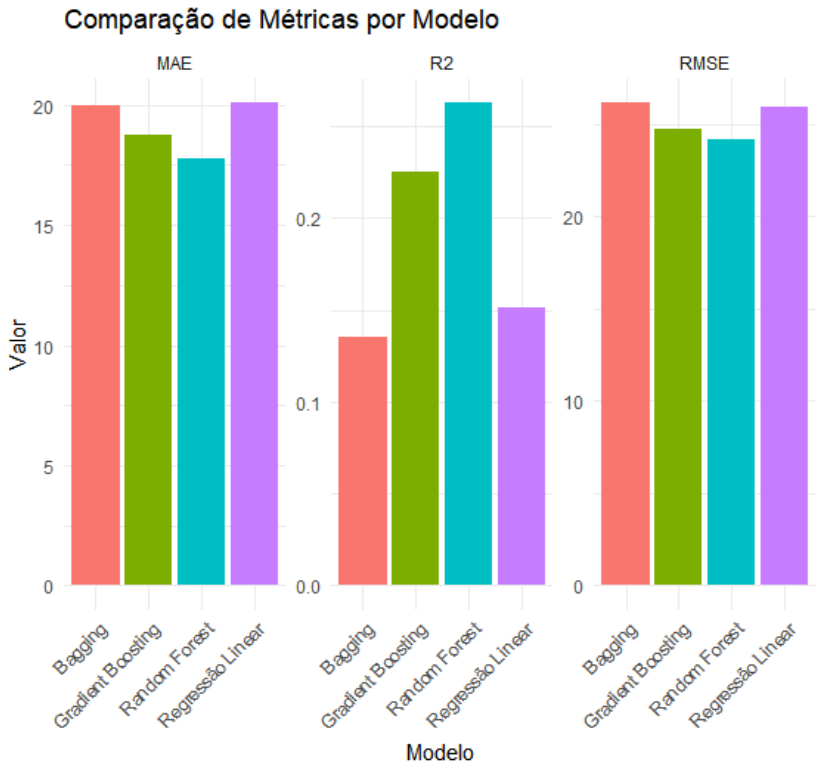
As variáveis relacionadas com as reviews fazem sentido serem importantes, uma vez que são um sinal de que o dono do alojamento pratica um preço justo para o que vende, o que facilita o trabalho de previsão do modelo. Um raciocínio parecido deve ser aplicado à variável mais importante. Possivelmente, um host mais experiente na área (com mais alojamentos) terá tendência a conhecer melhor o mercado e a aplicar preços mais justificáveis, logo mais previsiveis.

A importância de minimum_nights, mesmo sendo menor, pode refletir a distinção entre dois mercados diferentes: o mercado de turismo de curta duração (estadias de 1 a 3 noites,

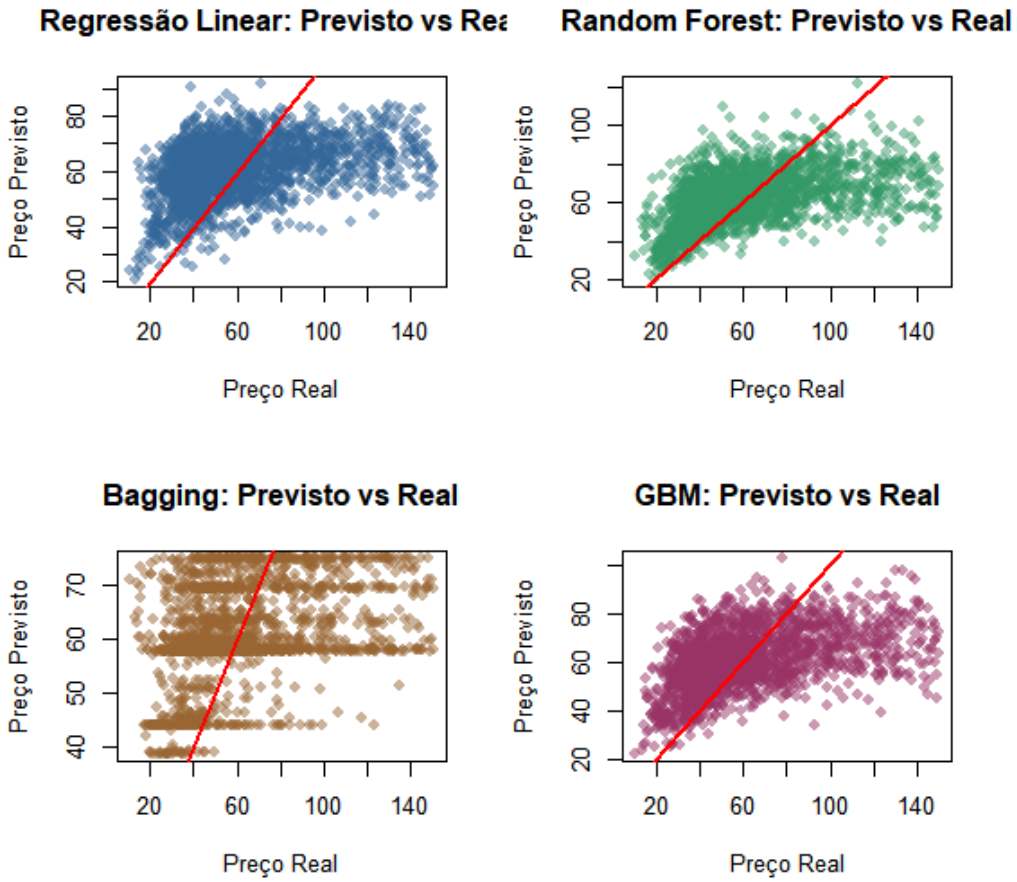
com preços por noite mais elevados) e o mercado de média/longa duração ou nómadas digitais (estadias > 30 noites, com preços base mais baixos). O modelo utiliza esta variável como um filtro para aplicar diferentes lógicas de preço a estes dois segmentos distintos.

6.5 Comparação

Mesmo sendo o objetivo do trabalho utilizar apenas o melhor modelo para fazer a previsão final, acabámos por testar todos para recolher uma comparação gráfica dos seus desempenhos:



As métricas para todos os modelos corroboram os resultados de treino com exceção do R^2 do modelo da Regressão Linear que parece ter aumentado ligeiramente, deixando, de forma não expectável, o Bagging como o modelo o pior desempenho tanto de RMSE como de R^2.



A regressão linear tem um desempenho bastante mais próximo da Random Forest e do GBM do que se esperava, mas é fácil de reconhecer que a "nuvem" que cria está consideravelmente menos centrada na linha de previsão perfeita. É importante também notar as escalas dos preços previstos, uma vez que esta depende da previsão máxima de cada modelo.

O Bagging é o modelo com o gráfico de previsão menos natural. Parece que está a sofrer com severamente de *underfitting*. Podemos observar uma estratificação de preços que não deveria ser vista num modelo bagging, para além de um tecto máximo completamente definido.

---

7. CONCLUSÃO

Os resultados da previsão, especialmente o R^2, para o modelo final, ficam próximos ou até melhores que o que se esperaria dadas as limitações da base de dados mas isto estará relacionado com a forma como os outliers foram identificados (através do IQR que é bastante generalista e não representa bem a disparidade de preços entre a esmagadora maioria do mercado que é bastante acessível e as estadias de luxo que chegam a valores muito acima daquilo que seria de esperar, que são muito menos representativos do mercado, sendo mesmo assim algo que nas boas práticas não se deveria ignorar.

A ausência de dados como a inclusão de ar condicionado, o número de quartos e casas de banho ou a área do alojamento, criam uma barreira à predição dos modelos de alojamentos mais caros. Verificámos isso mesmo com o corte que fizemos à volta dos 150 Euros por noite.

Reconhecendo a limitação das nossas conclusões dado o corte de outliers tomado na base de dados, achamos que desenvolvemos um trabalho com honestidade metodológica.